数据说明

1 数据集与规模

v1.0 提供完整处理后的业务与评测数据，具体范围见处理后数据交付范围。业务库、评测库、配套近邻与既有统计证据保持一致，按运行包清单及 SHA256 建立版本对应。

业务与评测两套 SQLite 分别保存、独立统计。以下为本次交付处理后数据快照统计；全部表的字段类型、主键和行数在 data-inventory.json，可运行 python scripts/submission_inventory.py 复核。

数据	表	行数 / 内容
自采文档	documents / document_versions	4190 文档 / 4339 版本
事件 / 要素	event_records / event_elements	1907 / 31137
原子主张 / 裁决	event_claims / claim_verdicts	3922 / 3922
披露证据段落	evidence_paragraphs	93209
重复	duplicate_clusters / duplicate_cluster_members	304 簇 / 1488 成员
传播	propagation_edges / propagation_components	2927 边 / 1401 分量
披露差异	disclosure_diffs	1212
问询	inquiry_questions / inquiry_triplets	16 问题 / 80 候选关联
事项	issue_ledger / issue_status_history	41 事项 / 117 机器状态记录
风险提醒	alerts	281
行情 / 财务	market_quotes / financial_indicators	2635 日线 / 114 数值
主办方评测	gold_articles / gold_event_labels / gold_event_schema	5327 文章 / 3075 标签 / 120 事件定义

平台案例是长鑫科技、药明康德。主办方语料包含更广公司 / 行业，仅用于独立评测与开发标定，不并入平台案例事实库。两套数据库分别用于业务展示与算法评价，统计与用途独立呈现。

数据时间范围按 2026-09-04 历史盘点记录：自采统计跨度 2024-01-02 至 2026-09-04，主办方语料统计跨度 2026-01-01 至 2026-05-29。该范围属于对应历史盘点；本次快照规模采用上表及字段清单。来源配置见 sources.yaml。S0 为政府、交易所、法院等权威原始来源；S1 为公司官网、公告镜像及授权问答；S2 为独立媒体和行业媒体；S3 为转载与聚合平台。来源层级评价权威性，来源独立性结合转载聚类与传播关系另行评价。

本轮 GPU 实验使用上述快照的 93209 段证据及 3922 条主张，输入文件 SHA256 及段落指纹与冻结向量快照一致。受控输入在独立 GPU 实验环境的.private 目录使用，报告仅分发输入摘要、编号 / 分数、性能采样与聚合效果；不向 Git 新增原始正文或模型权重。新近邻在独立目录完成导入和效果复核，现有运行快照中的裁决与近邻保持原样。

2 关键字段含义

字段组	意义
document_id / version_id / content_hash	文档标识、内容版本、原始内容哈希；通过哈希区分同 URL 的内容版本
company_id / source_id / source_tier	目标公司、来源站点、S0 ~ S3 证据等级；来源等级和来源独立性分别评价
published_at / published_basis / fetched_at	发布时间、时间推断来源、采集时间，三个维度独立存储
raw_path / extraction_status / inclusion_status	原始文件位置、解析结果、是否进入分析；跨环境复现按配置恢复相应路径
event_id / event_types_json / event_time / label_source	事件、类型集合、发生时间、模型或规则标签来源
raw_text / normalized_value / unit / basis / status	要素原文、归一值、单位、口径与归一状态
claim_id / source_start / source_end	原子主张和连续原文定位跨度
verdict / partial_subtype / method / confidence	四值核验、部分支持原因、方法、模型置信度；校准正确率按独立评价统计
evidence_version_id / evidence_page / evidence_text	被引用披露版本、页码、证据原文
issue_id / issue_code / status	持续事项实体、事项类别及生命周期状态
alert_id / level / risk_score	机器预警、等级、分数；人工判断另存处置表
username / role / recipient / actor / decided_at	账号、角色、收件人、人工操作者、记录时间；提交快照用新比赛账号

3 预处理

保留原始内容及版本 → 正文解析（HTML/PDF 等）→ 排除列表页、接口响应、无正文和非目标内容 → 时间与公司解析 → 规则守门 → 模型事件抽取 → 原文跨度校验 → 数量 / 币种 / 期间归一 → 披露段落索引 → 主张裁决与派生关系。

检索体做繁简折叠、中文二元组和拉丁词切分；展示与引用保留原文措辞。披露段落承担事实核验依据，行情和市场反应提供辅助对照；因果分析按专项识别协议评价。采集与解析状态完整留存，支持覆盖率复核及样本追溯。

4 脱敏与发布控制

部署快照不是生产数据库原样复制。SQLite backup 取得一致副本后，删除原生产账号哈希、人工复核 / 任务 / 分派、人工处置与审计、订阅与投递、通知与阅读记录、人工事项调整，并创建 5 个新的比赛账号。随后 VACUUM 清除空闲页中的旧哈希。源数据库不修改；清理表清单随证据提交。

发布控制已隔离密钥、真实.env、原账号配置、机器访问日志和个人会话 Cookie。公开文档中的公司名、人名及原文引用按来源保留，以支持实体识别和证据查证；非公开个人材料按独立审核与脱敏流程接入。

5 使用限制与复现边界

自采文本和公开披露的权利归原权利人，主办方评测数据按比赛授权使用。交付采用私有仓库授权或指定材料渠道，第三方数据的再利用按相应授权执行；公开镜像、商业分发与第三方转交需另行取得许可。

运行包提供已解析证据段落、结构化结果、处理后的主办方评测数据、匹配的检索近邻、前端和数据库，可直接运行原型并查看已有实验。正文片段属于处理后内容，保留必要公司、日期、来源 URL 及公开披露信息以支持证据追溯。处理后业务库与评测库独立保存，配套索引按段落指纹匹配，支持直接部署与评审复核。