模型、算法与参数说明

本系统采用预训练模型直接推理，通过提示词、规则校验和检索编排适配金融事件任务，并结合独立离线向量计算。算法参数以源文件及随库保存的 model_name / prompt_version 为准，问答模型配置和历史批处理结论分别管理。

1 方法与实现入口

方法	实现	参数 / 边界
事件抽取	processor/ai_label.py	event-label-v8；temperature=0；文本片段上限 12000 字符；默认 workers=1，可选 1 ~ 8；结构契约校验
数值归一与校验	processor/ normalize.py、claim_verdict.py	Decimal 处理单位倍率、币种和百分比；规则验证数值条件，披露证据与主张核验共同评价语义支持关系
证据检索	processor/claim_index.py	SQLite FTS5 BM25；中文二元组、繁简折叠；最多 20 稀有查询词，常见词占比阈值 0.08；段落最低 20 字符
主张核验	processor/claim_verdict.py	claim-verdict-v3；候选 5 条，每条最多 600 字符；每 25 条小批量提交；四值结果与 PARTIAL 子类
向量召回	scripts/gpu/ embed_neighbors.py	BGE-M3，L2 归一余弦；同公司内 top-k20；GPU 上 FP16；冻结 batch64、max_length512；4090D 全量复测见 08
混合 / 兜底	processor/dense_index.py	RRF_K=60、FUSION_DEPTH=20；fallback 最多追加 2 条 dense-only 候选；索引指纹防错配
研判助手	api/assistant.py	6 种只读工具；最多 6 步；问题 300 字符；观察 2400 字符；引用摘录 160 字符；单次网关 45 秒

方法	实现	参数 / 边界
近重复聚类	pipeline.py：build_duplicate_clusters	同公司候选；SimHash 8 bands、Hamming≤16；同标题 Jaccard≥0.72、纯正文≥0.86；同标题 containment≥0.80 且日期差≤7 天；模板数字否决默认关闭（TEMPLATE_TEXT_BAR=None）
版本比对	disclosure_diff.py：align_sections / diff_section	相邻版本正文 / 章节→数字、增加、删除、修改记录；REWRITE_SIMILARITY=0.60、段落最低 30 字符；METRIC_WINDOW=24、MIN_METRIC_CHARS=2、MAX_FIGURE_DIGITS=15；默认 prospectus、仅有页码版本
传播关联	propagation.py：duplicate_edges / sequence_edges	重复簇、裁决及同事项时序→有来源的传播边；REPOST=0.90、FOLLOW_UP=0.30、REACTION=0.15；回看 30 天 / 最多 40 候选
问询与披露关联	inquiry_align.py：align_question	问询结构、答复段落及披露差异→关联三元组；稀有共享词门槛 12、短问题分母 3、分数≥0.05、每问题最多 5 个差异
事项标签与行业约束	issue_codes.py、issue_scope.py：backfill、pipeline.py	文本预算 1800 字符、每事件最多 2 标签、issue-codes-v2；按公司行业校验标签，生命周期写入事项与状态历史
候选因果	causal_link.py：merge_candidates	五条候选路径→带方向与证据的候选关系；共享要素≥2、通用要素 cutoff=60、时间窗 90 天；显式引用回看 30 天、containment≥0.60；causal-link-v1、单侧文本 1200 字符、主张最多 5 条
查询	api/routes/、api/db.py	参数化 SQLite 查询、固定字段与分页；助手不生成任意 SQL，不执行模型自由输出 SQL

线上批量结论主要来自 qwen-plus；在线助手单独选 kimi-k3。模型权重和 API 密钥独立管理。temperature=0 用于降低采样随机性，模型名称、提示词版本与运行结果留存，支持远端服务版本变化时的结果追溯。

上述配置为提交源码默认参数；算法评价设计与样本口径统一见测试报告。关键方法如下：

- 聚类先按公司约束生成 SimHash 分带候选，再用标题与正文 Jaccard 判断相似性；同标题包含度分支支持短讯与长文转载匹配。成员与代表文档逐一比较，代表按发布时间选择。参数在 train 切分标定，test 按冻结配置评价；模板数字否决分支保留为默认关闭的可选实验开关。
- 版本比对按相邻披露版本对齐章节和段落，识别正文增删改与数值变化，并保留版本、页码及文本定位。问询关联将问题与披露差异按稀有共享词匹配，输出可供复核的候选三元组。
- 传播分析结合重复簇、同事项时间顺序和来源，形成转载、后续报道与反应边；同一传播分量用于来源独立性计数，边类型与分数按实现配置保存。
- 候选因果结合主张、显式引用、共享要素及时间窗生成候选，再输出带方向和证据的关系供人工研判；其评价按独立因果标注协议开展。
- 事项按标签及公司行业约束归并，维护机器状态历史；人工研判与处置独立留痕，支持机器依据和人工结论共同追溯。

聚类阈值来自对应 train 标定记录；传播、版本对齐和候选关系的默认阈值属于可配置工程参数，其实现契约与流程由回归测试验证，质量按各自标注集评价。

2 检索与裁决

BM25 承担平台证据搜索与助手查询；BGE-M3 通过离线 GPU 批处理生成近邻，向主张裁决提供可选 fallback / hybrid 输入。相似度用于候选排序，事实支持关系由披露证据与四值裁决评价。索引 paragraph_fingerprint 及输入 SHA-256 匹配校验确保近邻与当前段落版本关联正确。

裁决输出：SUPPORTED（得到支持）、PARTIAL（部分支持，包括时间 / 数量 / 主体 / 限定词 / 因果附加等）、CONFLICT（明确矛盾）、UNVERIFIABLE（当前证据不足）。非 UNVERIFIABLE 结果需要可定位披露依据。人工 review_decisions 和 alert_dispositions 是独立记录，不覆盖 claim_verdicts。

3 来源约束、安全控制与人工复核

系统实现材料与指令隔离、JSON 契约校验及工具白名单。助手引用与本次检索结果绑定，过滤缺少来源的句子，提供来源追溯、原文定位与人工复核入口。引用与回答的语义支持关系结合披露内容及业务复核确认，形成检索、解释、复核的闭环。服务状态通过 available 显式返回，离线模式保持查询、阅读、导出与协同可用。

4 实验复现

评测入口为 processor/benchmark.py，样本和运行记录随处理后评测库交付。事件类型、影响方向、近重复聚类的已测质量及分母见测试报告；证据裁决、数值支持和候选关系采用各自独立人工标注协议。参数与提示词选择使用 train，test 作为公开验证集报告冻结配置结果；独立盲测按另设数据协议执行。单元测试使用独立合成夹具验证实现契约。

```
python -m processor.benchmark --help
```

运行包已带处理后评测数据库，既有结果可直接查询 benchmark_runs 及 benchmark_metrics；重新评价按上述命令帮助选择任务、切分及模型配置，模型路径需配置自有 API。

向量导出不需要 GPU：

```
python -m processor.dense_index export --out artifacts/gpu-bundle
python scripts/gpu/embed_neighbors.py --help
```

GPU 环境配置 torch、sentence-transformers 与授权模型权重，计算产物回传平台导入与评测。正式结果使用真实 CUDA 与 BGE-M3；fake-encoder 作为独立联调模式使用。

5 GPU 已完成实验与扩展协议

本次已复现的 CPU 检索效果

冻结快照上的 CPU 评价复用已有 BGE-M3 近邻；4090D 全量重算及回传复核见 08。启发式检索标签基于同公司内至少两项显著数值共现或英文 6 词连续片段，排除主张自身源文档。跨语 195、数值 357、英文原句 842 三个样本集独立展示，去重联合为 1175 条主张；此处评价候选命中，独立人工事实评价按另设协议开展。

1175 条联合样本	BM25	Dense	Hybrid	Fallback
recall@5	0.8826	0.6689	0.8757	0.8826
实际候选中命中率	0.8826	0.6689	0.8757	0.8936

Fallback 在 BM25 五条候选上最多追加两条向量候选，实际候选命中率达到 0.8936，BM25 基线为 0.8826；该配置明确记录五条 / 最多七条的候选预算。经固定策略评价，提交方案保持 BM25 主路径和可选向量兜底，以保留英文原句检索表现。Hybrid 对照的跨语 recall@5 增益为 0.0052，英文原句 recall@5 变化为−0.0273；预先设定的全局替换标准为增益≥0.10 且损失≤0.02。完整分组、UNVERIFIABLE 子集与方案选择见 retrieval-evaluation.json。

4090D 完整计时与复现协议

本轮在独立 4090D 服务器对同一输入哈希、93209 段落 / 3922 查询、batch64 / max_length512 / top-k20 执行 3 次完整复测，实际 CUDA 采样、向量归一、查询覆盖与同公司范围检查均通过。全流程平均 58.028 秒，编码平均 57.360 秒，近邻平均 0.393 秒，驻留显存峰值 3493MiB，完整结果见 08 及 evidence/gpu-timing/。权重摘要、实际依赖和基准脚本摘要一并冻结。

三轮完整计算开始前先预热，编码 / 近邻阶段前后进行 CUDA 同步，均值、样本标准差、P95、torch 峰值及每 250ms GPU 采样分别记录。导入使用原 dense_index.install，在私有新目录完成摘要、段落指纹及 3922 条主张关联检查，冻结运行近邻和裁决不被替换。FP16 分数验收采用 0.005 舍入容差，原分数和排序保持不变。GPU 环境锁与安装要求独立于轻量平台依赖。

历史 V10032GB、同规模输入约 161.6 秒作为已有记录独立保留；历史模型 revision、驱动和软件未完整冻结，因此本轮分别报告设备结果，严格跨设备加速比另设同条件对照。双 V100 的实际多卡并行需有实现和日志。更多 GPU 硬件、batch、长度及训练实验按 07 扩展，计算性能与历史算法质量采用各自对应证据。