整体测试与效果评估

测试环境与验证范围

测试源码基线：58c47073c5cf3ab943c91900d8bf23cc133c59c7。业务评测环境采用 Linux、64 逻辑 CPU（双路 Hygon C86 7185）、约 128GB 内存；Python3.12、FastAPI0.141.1 / Uvicorn0.52.4、单 worker，前端以 Node22.22.2 构建。提交依赖锁采用 cryptography50.0.2 / urllib3 2.8.0，已完成独立新 venv 的功能与全量回归。持续负载实测采用 cryptography45.0.7 / urllib3 2.7.0，结果按对应实验版本分别记录。

公网入口完成轻量验收，压力写入在应用服务独立目录、SQLite 和 127.0.0.1:8013 端口执行。负载发生器位于应用服务，指标为本机应用端到端响应；公网网络与反向代理响应另行测量。4090D 完成独立离线 GPU 计算，设备及输入详情见 08。

已完成的工程验证

正式交付整理验证：本轮后端回归共 1829 项，1811 项通过、18 项按环境条件跳过；材料、访问安全、文档范围与演示附件专项检查 30 项通过。部署包说明及文档范围另有 12 项针对性检查通过。本地演示密码已与线上凭据分离，117 张非身份表逐行保持一致。部署信息与凭据扫描覆盖源码、正式报告、图像及发布附件；冻结版本的核验摘要见 Release 中的 RELEASE-VALIDATION.json。历史容量与 GPU 指标继续按原实验条件呈现。

项目	已验证成果	证据
前端单元 / 组件	31 文件、406 项通过，Node22.22.2 环境 7.51 秒	evidence/frontend-unit-final.log
前端源码构建	干净 npm ci 后构建成功，生成完整部署产物	evidence/frontend-build-final.log
公网 HTTP	45 项功能验收通过	evidence/production/acceptance.json
功能 / 权限 / 协同	65 项通过，覆盖完整业务流转与角色控制	evidence/isolated/acceptance.json
同身份并发意见保存	10 路均返回 200，10 条审计意见完整留存	同上
公网研判助手	SSE200、available=true，首次事件 0.136 秒、总 42.046 秒	evidence/production/assistant.json
浏览器页面	1512 浅色 31 页、2560 深色 7 页、1280 深色 9 页完成验证	evidence/ui/
干净原生部署	新目录、新 venv 和运行快照完成 65 项 HTTP 验收	evidence/clean-deploy/acceptance.json

项目	已验证成果	证据
提交依赖回归	1782 项通过，另 16 项环境条件检查；共 1798 项，345.411 秒	evidence/backend-clean-venv.log
最终 GPU 提交源码 CI	33a6e9f 快照：前端 406 项与构建通过；后端 1791 项通过、16 项环境条件检查，共 1807 项，115.406 秒	evidence/gpu-timing/github-ci-final-v101.json / log
GPU 扩展功能复验	新目录 18084 端口完成 65 项功能、权限与协同验收	evidence/gpu-timing/runtime-functional-acceptance.json
依赖安全审计	精确锁定依赖在审计时点 npm / pip 已知漏洞记录均为 0	evidence/npm-audit-final.json、pip-audit-final.json
数据关系与完整性	5 类关键关联孤立记录均为 0，两数据库 integrity_check=ok	evidence/data-consistency.json、data-inventory.json
凭证隔离	交付数据库中原生产 8 个账号哈希字节检索结果均为 0	evidence/credential-scrub-check.json
检索效果复核	1175 条固定启发式标签，Fallback 候选命中率 0.8936	evidence/gpu-timing/application-acceptance.json
4090D 全量 GPU 计算	93209 段落 / 3922 查询，3 轮均通过；平均 58.028 秒、样本标准差 0.342 秒	evidence/gpu-timing/benchmark.json，08 专项报告
GPU 回传接入	摘要、指纹、3922 条主张覆盖与公司范围检查通过	evidence/gpu-timing/application-acceptance.json
向量契约回归	35 项通过，覆盖导入、摘要、公司范围、分数排序与 FP16 容差	evidence/gpu-timing/cpu-contract-tests.log

最终源码 CI 与 GPU 实测快照分别记录，报告表述调整沿用上述已验证代码与原始实测数据。正式发布的源码、报告、运行包和校验文件按新交付标签匹配。

算法质量评价

质量结果对应历史冻结实验，采用处理后主办方评测库，与本轮工程验收和 GPU 计时分别统计。train 用于参数与提示词选择，test 为主办方提供的公开验证集；运行编号、代码摘要、数据与映射版本保存在 benchmark_runs、benchmark_metrics 中。程序入口为 benchmark.py，参数见算法说明。

评价对象	计分口径	实测成果与对照
近重复聚类	test 计分文档 1491；排除 291（跨切分关系 238、文本量条件 53），金标对 1298、预测对 980；同时报告 pair 与 B^3	pair precision=0.9959、recall=0.7519、F1=0.8569；B^3 precision=0.9973、recall=0.9583、F1=0.9774
事件影响方向	test 分层样本 475（正面 400、中性 39、负面 36）；少数类覆盖与正面封顶分别记录	模型 accuracy=0.8463、macro-F1=0.6568；同样本恒答正面 macro-F1=0.3048；按真实先验重加权 accuracy=0.8698
事件类型	test 映射后的 436 条样本，模型 event-types-v1 与规则同分母对照	模型 micro-F1=0.4660、macro-F1=0.4041；规则 micro-F1=0.3333、macro-F1=0.2849
事项议题码	test 按最稀有金标码分层、每码封顶 100，计分 675 条；issue-codes-v2 与检索示例对照	当前零样本 micro-F1=0.4211、macro-F1=0.3472；16 条检索示例对照为 0.6497、0.5614；同集 1-NN 为 0.6685、0.6318；检索示例从 train 获取，作为独立对照配置

聚类采用标题 0.72、正文 0.86、Hamming≤16、8 分带、包含度 0.80 及 7 天时间窗；train 标定后以冻结配置评价，排除计数随结果保留。分层影响方向准确率评价本次抽样，语料分布对应重加权指标；其目标是事件对指定主体的影响，稿件语气另行存储。事件类型按官方类型与系统议题 / 风险词表映射计分，采用最稀有金标类分层、每类封顶 100 条，当前金标支持 7 个系统类别；映射版本随运行记录保存。事件类型 train 同分母 488 条，模型 micro-F1=0.3890、macro-F1=0.3566，规则为 0.3726、0.3338；两切分的抽样构成分别记录。

证据裁决与数值支持结合原文定位、归一条件及人工复核评价；候选因果关系采用独立标注协议。流程契约验收、启发式检索候选命中、独立人工事实评价各自明确评价对象。后续质量覆盖与模板化披露区分的扩展见技术报告的适用范围与改进方向。

演示材料核验

30 页答辩 PPT 与 193.577 秒演示视频原样纳入 V1.0 交付。PPT 压缩结构可完整读取，视频完整解码通过；文件摘要与原始上传文件逐一匹配。抽样画面展示风险研判、证据与人工处置、研判助手、时间线、主张及披露比对、核验看板等核心流程。入口见演示材料，文件与 Release 校验清单统一对应。附件展示与业务专项实测分别呈现，测试指标保持原实验口径。

已实现的质量保障

测试夹具采用独立合成数据与冻结字段字典，复核、事项及通知写入全部重定向临时数据库，支持纯源码与干净环境重复验证。订阅权限按角色控制：管理员可查看 secret_ref 环境变量名称，密钥值独立管理；针对性权限回归及全量测试共同验证访问边界。

依赖更新后完成安全审计、Node22 构建、406 项前端测试与新 venv 回归。浏览器环境具备经校验的 Chromium 资产及运行依赖，页面检查与截图提供可查阅证据。安全审计结果对应已记录依赖版本及审计时点，系统软件、驱动与渗透测试按专项协议开展。

后端日志中 16 项条件性检查以 skipped 记录：7 项对应 Docker 守护进程 / SDK 环境，9 项对应授权 gold taxonomy JSON 文件映射。提交采用已完成干净部署验收的原生运行路径；Docker 和原始分类文件检查按相应环境配置执行，条件性检查与通过项分别统计。

分级并发与持续运行成果

50 个独立 analyst 账号使用各自 Session 和 Cookie，登录在计时前完成；1 秒思考时间，随机混合 9 类业务端点，约 90%查询、10%真实通知已读写入。分级阶段为 1 用户 30 秒、5 用户 30 秒、10 用户 60 秒、25 用户 120 秒、50 用户 1800 秒。逐请求状态与延迟、错误率、RPS、P50 / P95 / P99 及各端点指标完整留存。

预先设定交互目标为错误率≤1%、P95≤2000ms。业务负载测量查询与写入链路，GPU 及模型网关计算按独立实验统计。

用户	实际秒数	请求	异常请求	RPS	P95 毫秒	已验证范围
1	30.4	29	0	0.95	110.35	交互延迟目标范围
5	30.8	145	0	4.70	122.91	交互延迟目标范围
10	61.0	574	0	9.41	124.87	交互延迟目标范围
25	121.0	2736	0	22.61	259.02	交互延迟目标范围
50	1802.1	37479	0	20.80	3160.73	30 分钟持续运行可靠性；延迟为 2 秒目标的 1.58 倍

分级合计 40963 次请求，异常请求 0。25 用户 P95=259.02ms，验证本轮推荐交互规模；50 用户阶段连续运行 30 分钟、37479 次请求零异常，提供扩展容量的可靠性与性能基线。50 用户 P50=1160.06ms、P99=4370.84ms、最大 7479.03ms；其 P95=3160.73ms 相对 2000ms 目标为 1.58 倍，响应目标验证与压力可靠性验证分别呈现。

50 用户端点 P95：通知列表 4229.00ms、通知已读 3809.77ms、风险摘要 3635.17ms。load-identities.json 核对 50 个独立账号、50 个成功登录操作者及 50 个已读记录身份。原始结果见 evidence/load/load.json 及逐请求日志。

本次使用共享测试环境，结果体现该环境下的实际混合负载表现。30 / 40 用户及专用服务器峰值容量按后续分级协议测量。扩展优化以 CPU、SQL、通知同步 / 写锁及线程队列测量为依据，再按同输入、同脚本、同目标复验；GPU 批处理性能独立见 08。

功能覆盖与扩展路线

功能已覆盖检索、事件、证据、风险、事项、时间线、传播、重复、版本差异、评测、通知、导出、智能问答及离线模式。安全验证覆盖登录保护、角色隔离、输入校验、私网 Webhook 访问控制、引用范围和账号停用。协同实现完整状态流转及并发意见审计，本轮按单实例、同状态最后写入生效的语义验证。

GPU 已完成 BGE-M3 全量向量计算与平台回传，保持测试环境部署、机器裁决及冻结输入一致。外部 LLM 多路容量、300 条独立人工裁定、最终盲测、手机专项适配与多节点协同按专项协议扩展，各项指标按对应数据集和环境独立评价。