IssuerTrace GPU 向量计算专项测试报告

正式交付版本：v1.0。实验时间：2026-10-09T12:53:19.725606+00:00 至 2026-10-09T12:56:19.386922+00:00。GPU 代码快照：4685ccbd5da4207f79af2977eaacdff6986adc1a。

一、目标与运行架构

在独立 4090D 服务器复测冻结输入上的 BGE-M3 编码与同公司 top-k 近邻计算，补齐计算时间、吞吐、显存和回传接入证据。平台业务 API 继续使用原测试环境部署；向量计算是离线批处理，预计算产物回传平台，不要求业务页面实时加载 GPU 模型。

批处理通过原 scripts/gpu/embed_neighbors.py 的 ModelEncoder 和 topk_torch 执行，新增基准工具负责完整输入核对、预热、CUDA 同步、分段计时、采样与验收，不修改原编码与候选排序实现。

二、设备、模型与环境

设备：NVIDIA GeForce RTX 4090 D, 570.124.04, 24564 MiB, 425.00 W；实际使用 1 张卡，cuda:0，计算能力[8, 9]。AMD EPYC9754 宿主，容器 18 核 / 60GiB 配额；宿主与 cgroup 原始信息在 benchmark.json 中分别记录。

Python=3.10.15，torch=2.8.0+cu128，CUDA=12.8；依赖版本：{'sentence-transformers': '4.1.0', 'transformers': '4.55.2', 'tokenizers': '0.21.4', 'numpy': '2.2.6', 'huggingface-hub': '0.36.0'}。完整环境锁见 gpu-environment.lock.txt。

采用预训练 BGE-M3 的本地 Xorbits 镜像，输出 1024 维，CLS 池化与 L2 归一；本轮使用安全张量格式权重，推理为 FP16。镜像原 pytorch_model.bin 的 SHA256 与官方 BAAI/bge-m3 元数据所列文件一致；实际加载的 safetensors 及配置单独记录文件摘要。官方 revision 和元数据见 model-provenance.json。

实际加载 model.safetensors：993b2248881724788dcab8c644a91dfd63584b6e5604ff2037cb5541e1e38e7e，2271064456 字节。全部模型文件摘要在 benchmark.json；授权权重保留于 GPU 部署目录，不随仓库分发。

GPU 实验采用独立虚拟环境，通过只读公共 PyTorch/CUDA 依赖与独立安装的 sentence-transformers 组织运行；计算阶段采用负载隔离，保证计时条件一致。pip check 通过，实际生效版本及复现锁均记录。

三、冻结输入与实验参数

完整输入：93209 段披露证据、3922 条主张；两家公司分别编码和计算近邻。输入 SHA256 与冻结提交的 export 及既有向量清单一致；段落指纹：e131aea74bede795b702cc29eb548745fc98690a213ed3c1b88b529077f202f0。

paragraphs.jsonl SHA256：94497cac311765d5ac647819f732459022d2539a3a18d75c263f1716c856bcc6。queries.jsonl SHA256：0dc7ecc864ab7cb0d524766a6b82afd72410eb56e15bde958cdda4a4f012da6c。原始正文留在受控.private 目录，Git 中仅保存摘要及段落 / 主张 ID 和分数。

batch_size=64、max_length=512、top_k=20、FP16、归一化、seed=42、关闭 TF32。先用真实输入预热一批段落、一批查询及近邻，再执行 3 次完整计算，无 limit、无 fake-encoder。原始编码脚本与基准脚本 SHA256 均在 benchmark.json。

计时前后 torch.cuda.synchronize；编码耗时包含 tokenization 与实际模型执行，近邻耗时包含 GPU 矩阵运算、top-k 及 CPU 结果准备。全流程包含结果校验和文件写入，模型加载与预热单独记录并排除。每 250ms 用 nvidia-smi 采样驻留显存、利用率、功率和温度；torch 张量分配与缓存峰值另列，避免混淆指标。

四、完整 GPU 实测结果

重复	段落 + 查询编码秒	近邻秒	全流程秒	编码文本/秒
1	57.213	0.122	57.646	1697.70
2	57.511	0.367	58.131	1688.90
3	57.354	0.688	58.306	1693.54

重复	驻留显存峰值 MiB	张量分配峰值 MiB	GPU 利用率峰值%
1	3493.0	1897.407	100.0
2	3493.0	1897.407	100.0
3	3493.0	1897.407	100.0

全流程平均 58.028 秒，样本标准差 0.342 秒，中位数 58.131 秒，P95=58.289 秒。编码均值 57.360 秒，近邻均值 0.393 秒；分位数采用小样本线性插值，完整原始数据见 benchmark.json。

全部 3 轮完整计算通过；每轮 3922 条主张均获得同公司范围内 20 条候选，分数有限且按原实现排序。FP16 归一和点积采用 0.005 数值容差，保留原始分数、不裁剪或重排。重复输出哈希一致=True；各轮 neighbors 及 GPU 采样分别保存。

五、平台接入与效果复核

通过原 dense_index.install 接口核对输入摘要、段落指纹及输出摘要，将 GPU 回传产物安装到独立.private 目录；从只读快照加载全部 3922 条主张近邻，编号关联和覆盖检查通过。既有运行包与线上冻结近邻、机器裁决和阈值保持原样。

固定启发式检索标签复核 1175 条去重主张：BM25 recall@shown=0.8826，Dense=0.6689，Hybrid=0.8757，Fallback=0.8936。这些候选命中指标按 04 的标签与评价设计独立统计，人工事实评价采用另设裁定协议。完整分组、候选预算和方案选择见 application-acceptance.json。

GPU 验收工具与既有向量导入 / 检索契约共 35 项 CPU 回归通过，见 cpu-contract-tests.log；实际 CUDA 计算独立以本报告三轮结果验证。

六、复现与交付

```
# 平台：Python3.12，按授权快照导出，不导出账号和密钥
python -m processor.dense_index export --out <受控输入目录>
# GPU：独立环境，安装 scripts/gpu/requirements-submission.txt，准备授权模型
python scripts/gpu/submission_benchmark.py --bundle <输入目录> --model <模型目录> --reference-manifest <冻结 data/state/dense/manifest.json> --out <结果目录> --source-commit <40 位提交> --repeats 3 --batch-size 64 --max-length 512 --top-k 20
# 平台：重新生成固定标签并在新建隔离目录验收回传（不替换生产）
python -m processor.retrieval_eval build
python scripts/gpu/submission_acceptance.py --bundle <输入目录> --run <结果目录/run-1> --out <验收目录>
```

实际云端采用 PYTHONPATH 指定只读公共 GPU 依赖路径，HF_HUB_OFFLINE=1、OMP_NUM_THREADS=8；全新 GPU 环境按锁安装可独立复现，不要求保留另一项目。输入受数据授权约束，传输仅限获授权的部署环境；模型供应商密钥和服务器 SSH 口令独立管理。

七、结果口径与扩展方向

历史 V100161.6 秒与本次 4090D 结果按设备及运行版本分别归档。本轮固定输入哈希、模型资产摘要和算法参数，形成可重放的单卡计算基线；严格跨设备加速比、双卡并行及更多配置按同一模型资产和环境的对照协议扩展。

本轮完成向量计算性能与平台回传验证；业务 API 延迟、外部 LLM 生成容量和训练实验按各自链路评价。不同 batch / 长度、长期 GPU 容量和更多公司可按 07 协议扩展；已验证业务容量与性能基线详见 05。

技术来源：官方 BGE-M3 模型说明。